PROJET D'IHM 2026 · ÉTAPE 3

# Découper et indexer

Fragments de 300 à 600 caractères, recouvrement de 15 %, contexte d'indexation, recherche hybride — et la mesure qui dit si cela sert à quelque chose

## 1. Ce que l'étape devait faire

| Tâche du plan de développement | État |
|---|---|
| **Découper par bloc pédagogique, 300 à 600 caractères, avec 15 % de recouvrement** | **fait** — `ia/indexer.py` ( `decouper_cours` ), 8 tests unitaires dédiés |
| **Table dédiée avec vecteur** `vector(1536)` | **fait** — `ia_fragments_v2` , contrainte `CHECK (caracteres <= 600)` |
| **Index HNSW + recherche hybride (vecteurs + mots-clés français)** | **fait** — `db/06-index-v2.sql` , fonction `rechercher_fragments_v2()` |
| **Rejouer le jeu de test de l'étape 2** | **fait** — protocole avec partition réglage / mesure, `ia/evaluer_etape3.py` |
| **Critère de sortie : top-5 ≥ 85 %** | **100 %** sur la moitié mesure — **tenu** |

**Le problème que cette étape résout**

À l'étape 2, l'index contenait un bloc = un fragment, de 145 à 437 caractères, sans recouvrement. Le seuil de citation était donc inutilisable : à 0,00 aucune question hors domaine n'était refusée, à 0,15 le top-5 tombait à 70 %. Le découpage ne rend pas seulement la recherche plus juste, il rend le seuil *possible* — et c'est le seuil qui empêche l'agent de citer hors sujet.

## 2. Comment le corpus est découpé

| Règle | Valeur | Pourquoi |
|---|---|---|
| **Taille d'un fragment** | 300 à 600 caractères | En dessous de 300, le fragment n'a pas de contexte citable ; au-dessus de 600, la phrase utile se noie dans le paragraphe. |
| **Recouvrement** | 15 % (90 caractères) | Une réponse à cheval sur deux fragments reste trouvable : la fin du fragment précédent ouvre le suivant. |
| **Regroupement** | blocs consécutifs d'un même cours | Un texte et son exemple de code forment un seul fragment citable au lieu de deux moitiés. |
| **Préfixe contextuel** | Cours · Langage · Type | Il sert à **retrouver** le fragment (« length et size() en Java »), jamais à le citer : le texte affiché reste le cours, sans le préfixe. |
| **Couverture lexicale** | part des mots de la question présents | Ce que le vecteur de démonstration ne sait pas faire : distinguer `ArrayList` de « liste ». |

Résultat sur le corpus v1 : **36 blocs deviennent 25 fragments**, de 305 à 584 caractères, moyenne 449. Aucun fragment ne dépasse 600 — la contrainte est vérifiée en base ( `CHECK` ) et par un test, pas seulement par le script qui les fabrique.

**Un défaut trouvé par le test, pas par la mesure**

La première version du recouvrement prenait « la dernière phrase » du fragment précédent. Sur le cours *Boucles en C++*, cette phrase mesurait 40 caractères : le recouvrement valait 40, pas 90. Les chiffres de rappel ne le voyaient pas — un test de propriété, si. La règle est maintenant : au moins 66 % du recouvrement visé, sinon on coupe sur une frontière de mot.

# 3. Mesurer sans se mentir

Les 60 questions sont gelées depuis l'étape 2. Les régler puis les mesurer reviendrait à mesurer le réglage : elles sont donc partagées une fois, selon une règle écrite, avant toute exécution.

| Moitié | Questions | Usage | Empreinte |
|---|---|---|---|
| **Réglage** | 20 | choisir seuil, poids lexical, couverture | par notion : première question de chaque langage + 2 transversales (VAR, ERREUR) |
| **Mesure** | **40** | **seuls chiffres publiés** | sha256 dans le manifeste et le rapport |

## La frontière que le seuil ne savait pas tenir

Tableau lu sur la moitié **réglage** : pour chaque seuil, le meilleur compromis atteignable.

| Seuil | top-5 v1 | fuites v1 | top-5 v2 | fuites v2 |
|---|---|---|---|---|
| **0.00** | 100 % | 4/4 | 100 % | 4/4 |
| **0.05** | 90 % | 2/4 | 100 % | 3/4 |
| **0.10** | 80 % | 1/4 | 100 % | 2/4 |
| **0.15** | 70 % | 0/4 | 100 % | 1/4 |

Lecture : avec l'index v1, conserver toutes les questions légitimes impose d'accepter toutes les citations hors domaine. L'index v2 tient le top-5 à 100 % **et** ne laisse passer qu'une question hors domaine au seuil 0,15. C'est le résultat de l'étape.

## Réglage retenu

| Paramètre | index v1 | index v2 |
|---|---|---|
| **seuil_vecteur** | 0.0 | 0.15 |
| **poids_lex** | 0.0 | 0.0 |
| **bonus_couverture** | 0.0 | 0.15 |
| **top-5 sur la moitié réglage** | 100 % | 100 % |
| **top-1 sur la moitié réglage** | 80 % | 80 % |
| **configurations essayées** | 12 | 36 |

# 4. Le résultat sur les 40 questions de mesure

| Mesure | Étape 2 (v1) | Étape 3 (v2) | Écart |
|---|---|---|---|
| **top-1 : la bonne section sort en premier** | 72 % | 70 % | -3 pts |
| **top-5 : la bonne section est dans les cinq premiers** | 98 % | 100 % | +3 pts |
| **témoin présent dans le fragment cité en premier** | 75 % | 72 % | -3 pts |
| **témoin présent dans l'un des cinq fragments** | 92 % | 98 % | +5 pts |
| **top-1 sans filtre de langage** | 60 % | 68 % | +8 pts |

**100 %** **de top-5 sur les questions de mesure** — critère de sortie tenu (≥ 85 %), contre 98 % pour l'index de l'étape 2. Le top-1, lui, ne progresse pas (70 %) : c'est le plafond du vecteur de démonstration, pas celui du découpage.

### Par langage

| Langage | Questions | top-1 v1 | top-1 v2 | top-5 v1 | top-5 v2 |
|---|---|---|---|---|---|
| **python** | 12 | 75 % | 75 % | 100 % | 100 % |
| **java** | 12 | 83 % | 75 % | 100 % | 100 % |
| **cpp** | 12 | 67 % | 67 % | 92 % | 100 % |
| **tous** | 4 | 50 % | 50 % | 100 % | 100 % |

## 5. Ce que cette étape ne prouve pas

- **Le top-1 stagne à environ 70 %.** Un vecteur par plissement de hachage ne comprend pas la phrase : il rapproche des mots. Le découpage rattrape les cas où le bon passage est présent sans être premier — il ne remplace pas une sémantique.
- **Le poids lexical n'a pas pu être réglé.** Sur 20 questions, les trois valeurs essayées donnent le même résultat : le protocole retient la plus simple (0), et la moitié mesure n'autorise plus à revenir dessus. La branche lexicale reste active comme filet de rappel, pas comme pondération.
- **40 questions, c'est peu.** L'intervalle de confiance d'un taux approche ± 7 points : les écarts inférieurs à 10 points ne doivent pas être lus comme des victoires.
- **L'application de bureau n'utilise pas encore cet index.** Elle cite à l'unité de bloc depuis le corpus embarqué ; l'index v2 est la chaîne serveur (PostgreSQL + pgvector), celle que mesurent les chiffres et que branchera l'API REST.

## 6. Validation

| Élément | État |
|---|---|
| **Migration** | `db/06-index-v2.sql` — appliquée, table vide au départ, idempotente |
| **Découpage** | `ia/indexer.py` — 25 fragments, 305-584 caractères, 0 hors bornes |
| **Contrôle du découpage** | `python3 -m unittest test_decoupage` — **8 tests verts** |
| **Mesure** | `ia/evaluer_etape3.py` — 36 configurations essayées sur le réglage, mesure unique sur 40 questions |
| **Suite Java de la plateforme** | 74 tests — verts |
| **Décision** | Critère de sortie tenu : passage à l'étape 4 (stratégie de modèle) autorisé |