PROJET D'IHM 2026 · ÉTAPE 4

Stratégie de modèle

Trois options, cinq critères, une décision écrite — et la panne qui n'arrête jamais l'application · version **strategie-v1** du 2026-10-27

1. La question, et le principe qui la rend réversible

Le modèle n'est pas le sujet du projet : la plateforme l'est. Choisir un modèle, c'est choisir un fournisseur — donc un coût, une latence, une politique de données et une compétence d'exploitation. Le principe retenu avant toute comparaison :

> **Principe**
> Le modèle est un fournisseur interchangeable derrière une seule interface : le choix d'aujourd'hui ne doit pas devenir une contrainte technique demain.

Ce principe n'est pas une intention : il est porté par l'interface `ModeleIa`, par laquelle passent toutes les implémentations, et par un test qui lit les sources pour vérifier qu'aucun autre chemin n'existe. La décision d'aujourd'hui ne devient donc pas la contrainte de demain.

2. Les trois options comparées sur cinq critères

Les poids sont fixés avant la comparaison, ce qui interdit d'ajuster le barème au résultat attendu.

Critère	Poids	Comment il est mesuré	RAG · API	RAG · AUTOHEBERGE	FINE · TUNING
Qualité en français	30 %	Réponse juste, citée, dans un français correct, sur les 60 questions du jeu gelé	4 ★	4	2
Coût par 1 000 requêtes	20 %	Coût mensuel estimé au volume du projet, licence et hébergement compris	4 ★	2	2
Latence perçue	20 %	Temps entre l'envoi et l'affichage ; au-delà de 3 s l'apprenant abandonne	4 ★	3	4
Confidentialité des données	20 %	Ce qui sort de l'établissement : contexte d'aide, extraits de cours, code de l'apprenant	2 ★	5	4
Compétence requise pour maintenir	10 %	Ce qu'il faut savoir faire pour installer, surveiller et dépanner l'option	5 ★	2	1
Note pondérée	100 %	1 = rédhibitoire · 5 = excellent	**3.70** / 5	**3.40** / 5	**2.70** / 5

Les notes sont justifiées une par une ci-dessous ; la note pondérée est recalculée depuis le fichier par les tests, et la décision doit être l'option de meilleure note — sinon le tableau ne serait qu'un décor.

3. Ce que chaque option vaut, et pourquoi

Option	Argumentaire, critère par critère
API externe d'un modèle généraliste, avec RAG retenue **note 3.70/5**	• Les modèles généralistes récents répondent correctement en français ; la citation vient du corpus, pas du modèle. • Environ 20 $ par mois au volume du projet (52 800 requêtes), sans matériel à acheter. • 300 à 900 ms pour 300 jetons de sortie, sans file d'attente à gérer. • Point faible assumé : le contexte d'aide sort de l'établissement. Mitigé par le contenu du contexte, qui ne porte aucune donnée personnelle. • Une clé d'API et le SDK standard : rien à administrer, redémarrage immédiat si le fournisseur tombe.
Modèle auto-hébergé à poids ouverts, avec RAG **note 3.40/5**	• Mistral Small 4 (poids ouverts) est du même ordre sur ce type de question courte et citée. • Un GPU d'inférence revient à environ 365 $ par mois en location, ou à une machine dédiée à l'établissement plus son exploitation. • Excellente à chaud, mais dépend du dimensionnement et du temps de démarrage du service. • Aucune donnée ne sort : c'est la meilleure note du tableau. • Installation, mises à jour, supervision, redémarrage : une compétence d'exploitation que l'équipe projet n'a pas.
Apprentissage supervisé sur les données du projet écartée **note 2.70/5**	• Un modèle affiné sur quelques centaines d'exemples apprend la forme des réponses, pas le contenu des cours. • L'annotation de 2 000 exemples coûte environ 100 heures d'enseignant, à refaire à chaque évolution du corpus. • Rapide une fois servi, mais il faut servir le modèle, donc la même infrastructure que l'option auto-hébergée. • Les données restent internes, mais le modèle devient un artefact à versionner et à auditer. • Préparation de jeux de données, évaluation, réentraînement : hors de portée de l'équipe et du calendrier.

4. La décision

> **Retenir le RAG sur un modèle généraliste servi par API, derrière l'interface ModeleIa, avec le fournisseur encapsulé dans un seul transport.**
>
> Passer au modèle auto-hébergé plus tard ne change ni le service, ni les garde-fous, ni l'interface : seule l'implémentation du transport change.

Le coût, recalculé depuis les prix relevés

Hypothèse de volume : 120 apprenants × 20 questions par jour × 22 jours ouvrés = 52 800 requêtes par mois. Formule appliquée : `requêtes × (jetonsEntree × prixEntree + jetonsSortie × prixSortie) / 1 000 000`, avec 1400 jetons d'entrée et 300 jetons de sortie par requête.

Modèle retenu	Entrée	Sortie	Coût mensuel estimé
Mistral Small 4	0.15 $ / M jetons	0.60 $ / M jetons	**20.6 $** pour 52,800 requêtes

Relevé du 2026-10-27 · Prix relevés sur des pages publiques à la date du relevé ; à revérifier avant tout engagement, ils changent souvent.
Sources : https://docs.mistral.ai/inference/pricing · https://www.actuia.com/en/news/ai-api-pricing-in-october-2026-050-to-50-for-output/

Quand rouvrir la décision

- Si le volume dépasse 500 000 requêtes par mois, l'auto-hébergement devient moins cher.
- Si une donnée personnelle doit entrer dans le contexte d'aide, l'API externe devient inacceptable.
- Si le fournisseur change ses tarifs de plus de 50 %, la comparaison doit être refaite.

5. La panne : une réponse de première classe

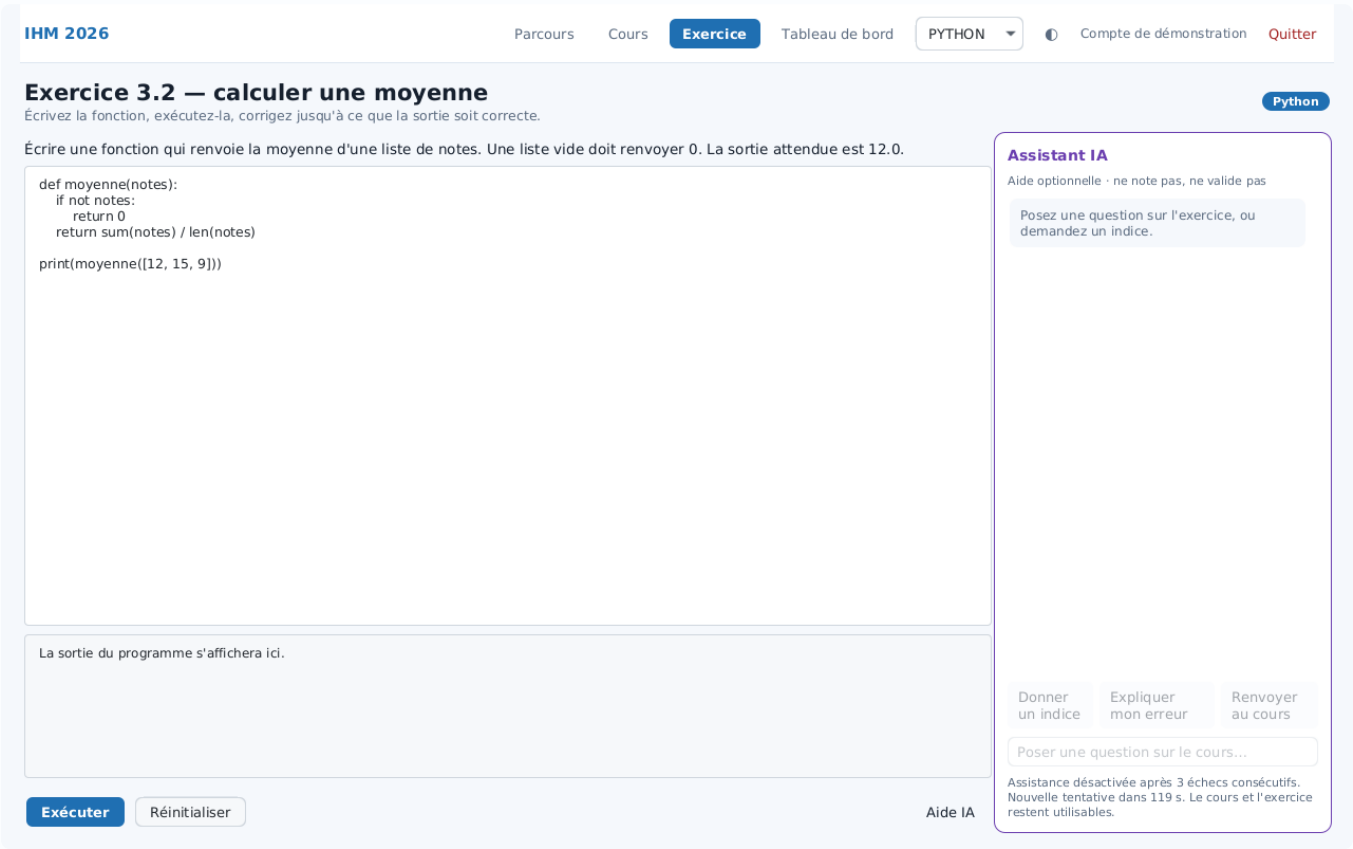
Aide désactivée, jamais un écran bloqué : la panne est une réponse de première classe (MotifRefus.INDISPONIBLE), l'écran de cours et l'éditeur continuent de fonctionner.

Paramètre	Valeur
Délai maximal d'un appel	3000 ms, une seule tentative
Disjoncteur	3 échecs consécutifs → ouverture 120 s

Les règles écrites

- Aucun appel au fournisseur sans clé d'API : l'indisponibilité est décidée avant tout appel.
- Un délai maximal de 3000 ms borne l'attente ; aucun appel n'est relancé automatiquement.
- Après 3 indisponibilités consécutives, le disjoncteur s'ouvre 120 secondes : plus aucun appel n'est tenté, l'IHM affiche l'aide désactivée.
- Une réponse sans citation est traitée comme une indisponibilité : elle ne serait pas affichable, donc elle n'est pas une réponse.
- Aucune donnée personnelle n'est transmise : le contexte d'aide est un record de quatre champs (rang, langage, question, code).

La preuve, prise sur l'application



Exercice 3.2, fournisseur simulé en panne : les commandes d'assistance sont neutralisées, la raison est affichée, et **le reste de l'écran continue de fonctionner** — « Exécuter » et « Réinitialiser » répondent encore. Capture produite par le smoketest, pas par une maquette.

6. Validation

Élément	État
Décision tracée	`strategie-modele.json` — 5 critères pondérés, 3 options, 3 conditions de réexamen
Cohérence décision ↔ notes	vérifiée par `StrategieModeleTest.decisionCoherenteAvecLesNotes` — note retenue 3.70 / 5
Coût	recalculé par un test depuis les prix du fichier (20.6 $ / mois)
Encapsulation du fournisseur	inventaire des sorties réseau vérifié sur les sources : `ApiClient` (serveur de la plateforme) et `TransportHttp` (fournisseur, seule classe qui lit la clé)
Politique de repli	délai, disjoncteur et reprise testés sans réseau ni attente réelle (horloge injectée)
Suite de tests de la plateforme	**89 tests**, dont 15 pour cette étape — verts
Application	10/10 écrans construits après modification du panneau (smoketest)
Décision d'étape	Critère de sortie tenu : aucun appel au fournisseur hors de l'interface — passage à l'étape 5 (prompts et format de sortie) autorisé